ENTER AI CHALLENGE · HACKATHON UFMG 2026 · GRUPO ESTRANGEIROS

Política de acordos, automatizada com rigor.

Um triador de processos que decide **defesa × acordo** em segundos — e sugere o valor ótimo para cada caso.

BANCO UFMG · 18 DE ABRIL DE 2026

PRESSIONE SPACE PARA AVANÇAR

O PROBLEMA

A cada mês, 5.000 processos chegam ao Banco UFMG alegando não reconhecimento de um empréstimo.

Para cada um, um advogado externo precisa decidir: **defender ou propor acordo?**

MAGNITUDE

Três números que redefinem o problema

5.000

PROCESSOS POR MÊS

Volume recorrente de casos de não reconhecimento

60.000

SENTENÇAS HISTÓRICAS NA BASE

Combustível para os modelos preditivos

R$ 300 M

EM EXPOSIÇÃO ANUAL ESTIMADA

60k casos × ticket médio de condenação

POLÍTICA DE ACORDOS

Três princípios. Zero jargão técnico.

01 — SELETIVIDADE

Só se propõe acordo quando o banco tem mais a perder indo até o final. Se a documentação sustenta a defesa, defendemos.

02 — VALOR ANCORADO EM RISCO

O valor do acordo nunca é arbitrário. É derivado da **condenação esperada** do caso, corrigida pela **probabilidade real de perda**.

03 — CONSISTÊNCIA AUDITÁVEL

Mesma política para todos os advogados externos. Cada decisão é **justificada**, **rastreada** e comparada com o que foi efetivamente feito.

A FRONTEIRA DE DECISÃO

Uma regra simples, tecnicamente ancorada

P(perder) > **60 %**

PROBABILIDADE ESTIMADA PELO MODELO

FRONTEIRA DE AÇÃO

ABAIXO DO LIMIAR

Defender

O banco tem subsídios suficientes. Custo esperado de ir até o final é menor.

ACIMA DO LIMIAR

Propor acordo

Exposição é alta. Negociar limita o prejuízo esperado.

VALOR DO ACORDO

Risk-adjusted, não arbitrário

$$\text{valor_acordo} = \alpha \times E[\text{condenação}]$$

A = 0,60

Fator de negociação calibrado. Abaixo disso, o autor rejeita; acima, o banco desperdiça exposição.

E[CONDENAÇÃO]

Predição de um modelo de regressão treinado em 60k sentenças, com transformação log para lidar com cauda pesada.

RESULTADO

Valor sugerido que minimiza prejuízo esperado — caso a caso, não por tabela fixa.

POTENCIAL FINANCEIRO

O que uma política consistente vale

R$ 60 M

ECONOMIA ANUAL ESTIMADA

Decisões mais acuradas × valores de acordo corrigidos pelo risco

40 %

MENOS TEMPO DE TRIAGEM

Advogado externo chega ao caso com a recomendação pronta

4 x

MAIS CONSISTÊNCIA

Mesma política aplicada entre todos os escritórios externos

Metodologia: base de 60k sentenças históricas (2024-2025) · ticket médio de exposição calculado por percentil 50 para evitar viés de cauda · economia = (Δ custo esperado entre política atual e política recomendada) × volume anual. Valores conservadores; cenário otimista chega a R$ 75 M.

EXPERIÊNCIA DO ADVOGADO

Da triagem à ação, em 3 passos

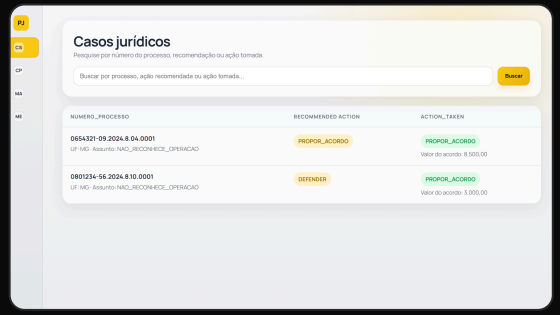

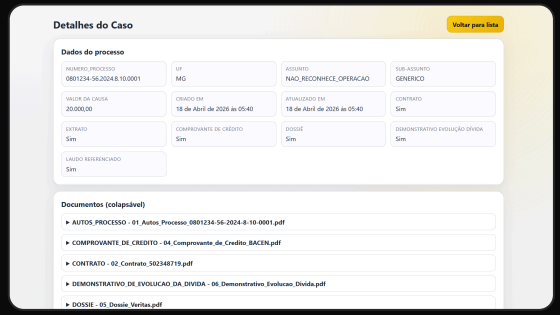

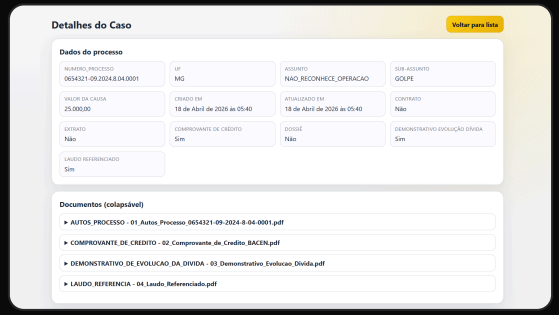

01 · TRIAGEM

O advogado abre a lista de processos. Busca unificada por número, UF, valor ou situação da recomendação.

02 · RECOMENDAÇÃO

Abre o caso e vê: probabilidade de perda, condenação esperada, ação sugerida e valor de acordo — com justificativa.

03 · AÇÃO

Registra a ação tomada em `LawyerAction` — valor de acordo ou resultado da defesa. O sistema calcula aderência (±20%) e shift % automaticamente.

Interface servidor-renderizada, sem curva de aprendizado. Importação em lote por pasta de subsídios gera recomendação no momento do cadastro.

ARQUITETURA

Pipeline em camadas, cada uma testável

Ingestão: pypdf + regex mapeia subsídios. Importação em lote por pasta padrão.

Features: 22 variáveis — score ponderado, interações `uf×assunto`, `combo_docs`.

Modelos: 2 checkpoints scikit-learn (risk: classif., cost: reg. log-transformada `expm1`).

Feedback: `LawyerAction` calcula aderência e shift % no `save()`.

O NÚCLEO DO CÓDIGO

6 linhas decidem tudo

```
1  def gerar_recomendacao_caso(case, settlement_factor=0.60)
2      features = _build_feature_row(case)
3      prob_perder = risk_model.predict_proba(features)[:, 1
4      valor_estimado = np.expm1(cost_model.predict(features
5      expected_loss = prob_perder * valor_estimado
6
7      if prob_perder > settlement_factor:
8          acao, valor = 'PROPOR_ACORDO', settlement_factor
9      else:
10         acao, valor = 'DEFENDER', None
11
12     return CaseRecommendation.objects.update_or_create(
13         case=case,
14         defaults={'sugestao_acao': acao, 'valor_para_acor
15                   'probabilidade_perder_caso': prob_perde
16                   'valor_esperado_condenacao': expected_l
```

7 / 7

Persiste a recomendação 1:1 com o caso. update_or_create permite reprocessar quando chegam novos subsídios.

MONITORAMENTO

Aderência e efetividade, em tempo real

ADERÊNCIA

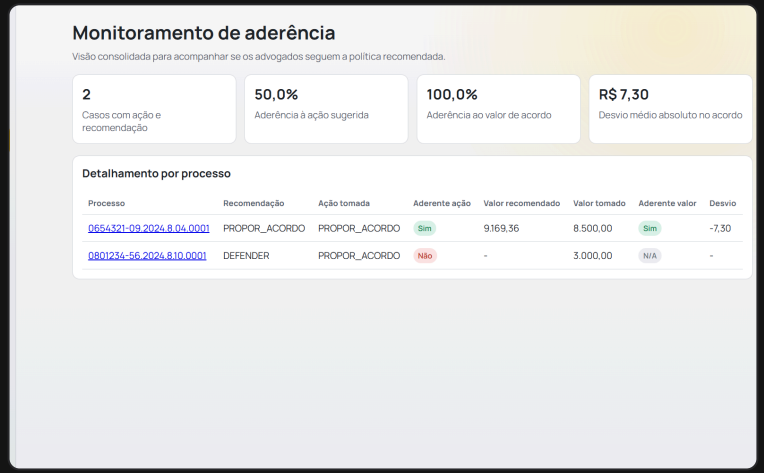

- · `aderencia_acao_pct` — % casos em que advogado seguiu a ação recomendada
- · `aderencia_valor_pct` — % acordos dentro da faixa ±20%
- · Desvio médio do `shift_valor_acordo` (%)

EFETIVIDADE

- · `taxa_efetividade_pct` — custo observado ≤ +20% da condenação esperada
- · `taxa_exito_defesa_pct`, `taxa_conversao_acordo_pct`, economia líquida
- · Matriz de confusão recomendado × tomado · seguiu

LIMITAÇÕES CONHECIDAS

Transparência sobre o que ainda não resolvemos

01 **Features limitadas aos subsídios estruturados.** O modelo não lê os autos em linguagem natural — ainda. Fica cego a nuances argumentativas da petição inicial.

02 **Fronteira α = 0,60 é global.** Uma UF ou perfil de autor pode ter dinâmica diferente. Calibração por segmento é próximo passo.

03 **Viés histórico na base.** Modelo aprendeu com decisões passadas — se a política atual já era subótima, parte do viés está embutido. Mitigamos com aprendizado contínuo.

04 **Sem LLM no loop de decisão.** Decisão atual é determinística e auditável. Ganhamos explicabilidade, perdemos nuance textual — troca consciente.

PRÓXIMOS PASSOS

O que construímos em 1 mês adicional

SEMANA 1

LLM para leitura de autos

Extrair sinais semânticos da petição inicial (fraude, coação, fatos específicos) como feature adicional.

SEMANA 2

Calibração por segmento

α específico por UF, sub-assunto e perfil de autor. Modelo de custo por segmento.

SEMANA 3

Retreino automático

`LawyerAction` já captura a ação tomada a cada caso. Próximo passo: pipeline de retreino mensal com shadow testing de novos limiares α antes de promover.

SEMANA 4

Motivo estruturado de divergência

Quando o advogado diverge da recomendação, capturar o motivo em forma categorizada — feature adicional para o próximo ciclo de treino.

> A justiça é a constante e perpétua vontade de dar a cada um o que é seu. Medir o risco é o primeiro ato dessa vontade.

— a partir de Ulpiano · Digesto, I, 1, 10

OBRIGADO · PERGUNTAS?